Relatório do Projeto 1

Busca e Organização de Dados

SCC0202 — Algoritmos e Estruturas de Dados I

Integrantes:

17881457 – Bernardo Schramm Schutz Machado

17899853 – João Pedro Cremasco Luiz

15580336 – Thomas Riki Hashima

Parte 1: registros de aproximação de asteroides (`asteroid_dataset_20251019.csv`, 89.227 registros).
Parte 2: registros de jogos publicados na Steam (`games.csv`, 125.855 registros).
Ambiente: Linux x86_64, Intel Core i5-10210U (4 núcleos, 8 threads, 15 GiB de RAM), GCC com `-std=c99 -Wall -Wextra -pedantic`. O executável `trabalho` é gerado por `make`.

1 Organização do código

O programa lê um CSV, guarda cada linha como um ITEM na estrutura escolhida por `--base`, percorre essa estrutura aplicando a consulta, insere os itens aceitos na estrutura escolhida por `--result` e exporta até `top-k` registros. O fluxo é: leitor → ITEM → base → busca com a consulta → resultado → exportação → CSV.

Tabela 1 — Módulos do programa e suas responsabilidades.

Módulo	Responsabilidade
`src/item.c`	ITEM: conjunto de pares nome da coluna/valor em texto, independente do domínio. ITEM_STORE: dono de todos os itens criados.
`src/reader.c`	Lê o cabeçalho, detecta o delimitador (vírgula, ponto e vírgula ou tabulação), trata campos entre aspas e vazios e cria os itens. É o único módulo específico de cada dataset (`--reader nasa`, `--reader games`).
`src/query.c`	Interpreta `FILTER`, `SIM`, `ACCEPT`, `ORDER`, `GROUP` e `CROSS`; decide se um item é aceito e calcula a similaridade.
`src/collection.c`	Interface comum às oito estruturas (criar, inserir, percorrer e destruir), com um `switch` sobre o tipo escolhido.
`src/export.c`	Escreve o CSV na ordem e no delimitador da entrada; em jogos, usa o cabeçalho corrigido para separar
textttDiscount e textttDLC count.	
`src/main.c`	Argumentos, medição de tempo, orquestração e saída padrão.
`data_structures/`	Oito TADs, um por arquivo, cada um com o seu nó ou vetor.

Os itens são guardados como texto e convertidos para número apenas quando uma consulta pede (`strtod`). Assim, valores ausentes não interrompem a leitura e o arquivo de saída reproduz o valor original.

2 Estruturas de dados

Todas as estruturas foram implementadas pelo grupo, sem contêineres de bibliotecas externas. Elas não conhecem o conteúdo dos itens: guardam ponteiros genéricos, e o módulo `collection` converte para ITEM em um único ponto.

Os nomes do enunciado (`pilha`, `fila`, `lista_seq`, `lista_enc`, `lista_cabeca`, `lista_ord`, `lista_gen`, `lista_cruz`) também são aceitos.

Tabela 2 — Estruturas implementadas e o que diferencia cada uma.

Estrutura	Argumento	Implementação	O que a diferencia
Pilha	`stack`	vetor redimensionável	Inserção e remoção no topo; percurso do topo para a base.
Fila	`queue`	nós encadeados	Inserção no fim, remoção no início; percurso da frente para o fim.
Lista sequencial	`array_list`	vetor redimensionável	Acesso por índice; a remoção desloca elementos.
Lista encadeada	`linked_list`	nós duplamente encadeados, ponteiros para o primeiro e o último	Inserção no fim em tempo constante; remoção em qualquer posição.
Lista com cabeça	`sentinel_list`	encadeada com sentinela real	O sentinela não representa registro; inserção, busca, remoção e percurso partem dele.
Lista ordenada	`ordered_list`	vetor mantido em ordem	A posição é localizada por busca binária e o elemento é inserido já na ordem de `ORDER`, sem ordenar ao final.
Lista generalizada	`generalized_list`	átomos e sublistas	`GROUP` cria grupos e subgrupos (por exemplo, categoria e depois ano); o percurso é em profundidade e visita apenas os itens.
Lista cruzada	`crossed_list`	nós esparsos por par de chaves, ligados nas dimensões	A coleção guarda em cada célula os itens que compartilham o par de valores de `CROSS`.

3 Consultas e exemplos de execução

A consulta é um arquivo texto com campos separados por `|`. `FILTER` define condições obrigatórias (`==`, `!=`, `<`, `<=`, `>`, `>=`; numéricas quando os dois valores são números). `SIM` define um critério de similaridade

$$s(x, q, t) = \max\left(0,\ 1 - \frac{|x - q|}{t}\right),$$

e a similaridade total é a média ponderada dos critérios. `ACCEPT` define o limiar mínimo. `ORDER`, `GROUP` e `CROSS` configuram a lista ordenada, a generalizada e a cruzada.

3.1 Parte 1 — Asteroides

Exemplo 1 — filtro e similaridade. Consulta `queries/asteroids_by_risk.txt`:

```
FILTER|distance_au|<=|0.08
SIM|velocity_km_s|15.0|10.0|1.0
SIM|risk_score|0.70|0.30|2.0
ACCEPT|0.60
```

```
./trabalho --reader nasa --input asteroid_dataset_20251019.csv --base linked_list --result
    ↪ array_list --query queries/asteroids_by_risk.txt --output resultados/asteroids_by_risk.csv --
    ↪ top-k 100 --limit 10000
```

Exemplo 2 — resultado ordenado. Consulta `queries/asteroids_ordered.txt`:

```
FILTER|distance_au|<=|0.08
ORDER|risk_score|DESC
```

```
./trabalho --reader nasa --input asteroid_dataset_20251019.csv --base queue --result ordered_list --
    ↪ query queries/asteroids_ordered.txt --output resultados/asteroids_ordered.csv --top-k 50 --
    ↪ limit 10000
```

Exemplo 3 — agrupamento e índice cruzado. Consulta `queries/asteroids_group_cross.txt`:

```
FILTER|distance_au|<=|0.1
GROUP|threat_category|year
CROSS|threat_category|year
```

```
./trabalho --reader nasa --input asteroid_dataset_20251019.csv --base generalized_list --result
    ↪ crossed_list --query queries/asteroids_group_cross.txt --output resultados/
    ↪ asteroids_group_cross.csv --top-k 100 --limit 20000
```

3.2 Parte 2 — Jogos

Os mesmos TADs são reutilizados, e apenas o leitor muda (`--reader games`). Esse leitor separa os nomes `Discount` e `DLC count`, que aparecem unidos no cabeçalho do arquivo fornecido.

Exemplo 4 — agrupamento por gênero e idade mínima. Consulta `queries/games_by_genre.txt`:

```
FILTER|Windows|==|true
FILTER|Price|>=|1
FILTER|Price|<=|100
SIM|Peak CCU|500|1000|1
ACCEPT|0.4
GROUP|Genres|Required age
```

```
./trabalho --reader games --input games.csv --base linked_list --result generalized_list --query
    ↪ queries/games_by_genre.txt --output resultados/games_by_genre.csv --top-k 100 --limit 10000
```

Exemplo 5 — índice cruzado. Consulta `queries/popular_games_by_genre.txt`:

```
FILTER|Peak CCU|>=|1000
FILTER|Windows|==|true
CROSS|Genres|Windows
```

```
./trabalho --reader games --input games.csv --base array_list --result crossed_list --query queries/
    ↪ popular_games_by_genre.txt --output resultados/popular_games_by_genre.csv --top-k 100 --
    ↪ limit 10000
```

Exemplo 6 — outra combinação de TADs. Consulta `queries/popular_games_ordered.txt`:

```
FILTER|Windows|==|true
FILTER|Peak CCU|>=|1000
ORDER|Peak CCU|DESC
```

```
./trabalho --reader games --input games.csv --base array_list --result ordered_list --query queries/
    ↪ popular_games_ordered.txt --output resultados/popular_games_ordered.csv --top-k 100 --limit
    ↪ 10000
```

3.3 Resultados dos seis exemplos

Os seis exemplos foram reexecutados três vezes nesta auditoria; as medições individuais estão em `resultados/examples_raw.csv`. Os arquivos de asteroides mantêm o cabeçalho original. O arquivo de jogos tem o nome `DiscountDLC count` unido no cabeçalho, embora os registros tenham duas colunas; o leitor o separa em `Discount` e `DLC count`, e a exportação usa esses nomes corrigidos. A ordem das colunas e o delimitador são mantidos.

Tabela 3 — Resultados dos exemplos de execução (médias de três execuções, tempos em ms).

Ex.	Base → resultado	Lidos	Enc.	Exp.	Carga	Busca	Ins. res.	Escrita
1	`linked_list→array_list`	10.000	93	93	91,794	13,293	0,010	0,853
2	`queue→ordered_list`	10.000	5.501	50	74,342	15,694	85,696	0,490
3	`generalized_list→crossed_list`	20.000	12.919	100	137,972	29,708	6,710	0,845
4	`linked_list→generalized_list`	10.000	6.145	100	512,497	21,991	15,895	4,561
5	`array_list→crossed_list`	10.000	43	43	524,614	4,484	0,065	2,738
6	`array_list→ordered_list`	10.000	43	43	494,867	7,803	0,100	2,653

4 Memória

Os itens pertencem ao ITEM_STORE. As estruturas guardam ponteiros emprestados e liberam apenas o que alocam para se organizar (nós, vetores e índices). Assim, o mesmo item pode estar ao mesmo tempo na base, no resultado e nos dois índices da lista cruzada, sem cópia e sem liberação dupla. No fim da execução, as coleções são destruídas primeiro e o store por último.

Os seis exemplos executados com AddressSanitizer e UndefinedBehaviorSanitizer terminaram sem erros reportados, com a detecção de vazamentos do LeakSanitizer desativada por incompatibilidade do ambiente. Valgrind não encontrou erros nem vazamentos nos exemplos 1, 3, 4 e 5, nem na suíte dos TADs.

5 Complexidade assintótica

Seja n o número de itens armazenados, k o número de registros exportados, p o número de campos por item, g o número de grupos, s o de subgrupos examinados, m o de itens no subgrupo, r e c o número de chaves distintas dos índices da lista cruzada, h os itens no bucket da célula e d_r e d_c os graus da linha e da coluna percorridas.

Carregar n itens custa $O(n)$ amortizado em pilha, fila e listas simples. Na lista ordenada pode custar $O(n^2)$ pelos deslocamentos, e na generalizada e na cruzada depende da quantidade de chaves distintas e dos graus. A busca da consulta percorre os n itens da base independentemente da estrutura. Como `item_get` percorre linearmente os p campos do item, o custo é $O(n(f+q)p)$ para f filtros e q critérios `SIM`, mais a inserção dos aceitos e a gravação do campo `similarity`, que acrescenta um campo ao item. A exportação custa $O(kp^2)$, pois cada uma das p colunas é procurada no item, mais a escrita dos caracteres.

Tabela 4 — Complexidade das operações realmente usadas pelo programa.

Estrutura	Inserção	Busca / percurso	Remoção
Pilha	$O(1)$ amortizado; $O(n)$ ao redimensionar	$O(n)$	$O(1)$ no topo; localizar item arbitrário $O(n)$
Fila	$O(1)$	$O(n)$	$O(1)$ na frente; localizar item arbitrário $O(n)$
Lista sequencial	$O(1)$ amortizado no fim	$O(n)$	$O(n)$, pois busca e desloca
Lista encadeada	$O(1)$ no fim (ponteiro final)	$O(n)$	$O(n)$ para localizar; $O(1)$ para religar
Lista com cabeça	$O(1)$ no fim	$O(n)$	$O(n)$ para localizar; $O(1)$ para religar
Lista ordenada	$O(n)$: busca binária $O(\log n)$ mais deslocamento $O(n)$	$O(\log n)$ por chave; $O(n)$ para percorrer	$O(n)$
Lista generalizada	$O(g+s)$ para achar ou criar grupo e subgrupo; $O(1)$ para anexar	$O(n)$	$O(g+s+m)$ no pior caso
Lista cruzada	$O(r+c+d_r+d_c)$ para célula nova; $O(r+c)$ para anexar em célula existente	$O(n)$ total; $O(d_r)$ ou $O(d_c)$ por linha ou coluna	$O(r+c+h)$ para localizar chaves e item no bucket

6 Avaliação experimental

6.1 Protocolo

- Base `linked_list` e resultado `array_list`, nos dois datasets, com as consultas `queries/asteroids_benchmark.txt` (`FILTER|distance_au|<=|0.1`) e `queries/games_benchmark.txt` (`FILTER|Windows|==|true`).
- Seis pares de `--limit` e `--top-k`: (1.000, 10), (5.000, 50), (10.000, 100), (25.000, 500), (50.000, 1.000) e (0, 0), em que zero significa toda a base e todos os resultados.
- Cada configuração teve uma execução de aquecimento, descartada, e três execuções medidas. As tabelas mostram a média aritmética e o desvio padrão amostral ($\pm$). As 36 medições individuais estão em `resultados/benchmark_raw.csv`.
- A coluna N é o número de registros lidos (`INPUT_RECORDS`).

6.2 Metodologia de medição

Os tempos são medidos dentro do próprio programa com `clock()` de `time.h` (C99), que devolve o tempo de CPU do processo, usuário mais sistema, em ticks de 1/`CLOCKS_PER_SEC` (1 µs no Linux), convertido para milissegundos. Cada fase é delimitada por duas leituras do relógio. Como o relógio mede CPU e não tempo decorrido, esperas por disco não entram nas medições, e os valores de carga e de saída não equivalem à latência percebida pelo usuário.

A busca e a inserção no resultado são feitas em duas passadas. Na primeira, `collection_visit` avalia os critérios de cada item, grava o campo `similarity` e guarda o ponteiro dos itens aceitos em um vetor. Na segunda, um laço insere todos eles na estrutura do resultado, com um único par de chamadas a `clock()` ao redor do laço inteiro. Assim, a busca não inclui a inserção, e o relógio não é lido uma vez por item. Não entram nas medições a abertura do arquivo de entrada, a leitura da consulta, a criação e a destruição das estruturas e a inicialização do processo, e por isso a coluna Total é a soma das quatro fases, e não o tempo de parede do programa.

A medição por item faria duas leituras de `clock()` para cada inserção e repetiria esse custo muitas vezes. Por isso, o programa mede o laço inteiro em bloco.

A máquina não estava isolada. Não foi registrado um snapshot da carga do sistema imediatamente antes desta série, então não dá para separar a variação do programa da atividade concorrente. As Tabelas 6 e 7 usam as abreviações do glossário abaixo.

Tabela 5 — Glossário das colunas das tabelas de tempos.

Coluna	Saída do programa	O que mede
N	`INPUT_RECORDS`	Registros lidos da entrada, limitados por `--limit` (0 lê toda a base).
k	`OUTPUT_RECORDS`	Máximo de registros exportados, definido por `--top-k` (0 exporta todos).
Carga	`LOAD_MS`	Laço que lê cada registro do CSV (leitura, separação de campos e criação do ITEM) e o insere na estrutura da base.
Busca	`SEARCH_MS`	Percurso da base com `colletion_visit`, avaliando `FILTER`, `SIM` e `ACCEPT` em cada item e guardando os aceitos em um vetor (primeira passada).
Ins. res.	`RESULT_INSERT_MS`	Laço de `colletion_insert` que passa os itens aceitos para a estrutura do resultado (segunda passada), medido em bloco.
Saída (Escrita)	`WRITE_MS`	`export_write`: abrir o arquivo, escrever o cabeçalho, percorrer o resultado até k e gravar as linhas.
Total	—	Soma de Carga, Busca, Ins. res. e Saída.
Enc. / exp.	`MATCHED_RECORDS` / `OUTPUT_RECORDS`	Registros aceitos pela consulta e registros exportados.

6.3 Resultados

Tabela 6 — Asteroides (89.227 registros no arquivo), `linked_list` → `array_list`. Média ± desvio padrão, em ms.

N	k	Carga	Busca	Ins. res.	Saída	Total	Enc. / exp.
1.000	10	12,150 ± 0,148	3,075 ± 0,816	0,028 ± 0,001	0,376 ± 0,071	15,629 ± 0,785	649 / 10
5.000	50	28,606 ± 0,854	6,070 ± 0,123	0,053 ± 0,001	0,420 ± 0,003	35,149 ± 0,965	3.195 / 50
10.000	100	56,270 ± 3,523	11,929 ± 0,552	0,112 ± 0,002	0,661 ± 0,049	68,972 ± 3,846	6.323 / 100
25.000	500	155,548 ± 5,775	30,834 ± 2,016	0,306 ± 0,006	3,269 ± 0,833	189,957 ± 6,804	15.249 / 500
50.000	1.000	332,364 ± 49,712	69,944 ± 7,257	0,590 ± 0,057	6,951 ± 0,442	409,849 ± 57,150	24.012 / 1.000
89.227 (toda)	todos	434,041 ± 12,547	103,079 ± 8,536	0,839 ± 0,129	191,707 ± 18,858	729,666 ± 12,017	39.380 / 39.380

Tabela 7 — Jogos (125.855 registros no arquivo), `linked_list` → `array_list`. Média ± desvio padrão, em ms.

N	k	Carga	Busca	Ins. res.	Saída	Total	Enc. / exp.
1.000	10	62,656 ± 3,973	2,507 ± 1,323	0,019 ± 0,003	0,603 ± 0,052	65,785 ± 5,257	1.000 / 10
5.000	50	245,154 ± 2,946	7,924 ± 0,222	0,080 ± 0,009	2,010 ± 0,192	255,168 ± 3,007	4.998 / 50
10.000	100	490,325 ± 35,630	19,631 ± 0,230	0,180 ± 0,006	4,009 ± 0,138	514,145 ± 35,589	9.996 / 100
25.000	500	1.201,504 ± 59,925	43,898 ± 0,777	0,524 ± 0,020	19,399 ± 1,924	1.265,325 ± 59,430	24.989 / 500
50.000	1.000	2.402,729 ± 55,795	98,035 ± 7,579	1,086 ± 0,170	38,935 ± 2,185	2.540,785 ± 49,296	49.978 / 1.000
125.855 (toda)	todos	6.193,084 ± 105,172	246,937 ± 14,470	2,433 ± 0,087	4.342,640 ± 78,843	10.785,094 ± 85,417	125.811 / 125.811

Figura 1 — Tempo médio de carga e de busca em função do número de registros lidos, para os dois datasets (valores das Tabelas 6 e 7).

6.4 Custo por registro

Para comparar com o crescimento esperado, a Tabela 8 divide os tempos médios pelo número de registros lidos (carga e busca) ou exportados (saída), em microssegundos.

Tabela 8 — Custo por registro (µs), calculado com as médias não arredondadas de `benchmark_raw.csv`.

Dataset	N	Carga / lido	Busca / lido	Ins. / aceito	k	Saída / exp.
Asteroides	1.000	12,15	3,08	0,04	10	37,63
Asteroides	25.000	6,22	1,23	0,02	500	6,54
Asteroides	89.227	4,86	1,16	0,02	39.380	4,87
Jogos	1.000	62,66	2,51	0,02	10	60,30
Jogos	25.000	48,06	1,76	0,02	500	38,80
Jogos	125.855	49,21	1,96	0,02	125.811	34,52

6.5 Custo de inserir no resultado, por estrutura

A Tabela 9 divide o tempo de inserção pelo número de itens aceitos.

Tabela 9 — Custo de inserção no resultado por estrutura, nos exemplos da Seção 3.

Ex.	Estrutura do resultado	Itens inseridos	Ins. res. (ms)	Por item (µs)
1	`array_list`	93	0,010	0,10
2	`ordered_list`	5.501	85,696	15,58
3	`crossed_list`	12.919	6,710	0,52
4	`generalized_list`	6.145	15,895	2,59
5	`crossed_list`	43	0,065	1,50
6	`ordered_list`	43	0,100	2,32

Figura 2 — Custo de inserção por item nos seis exemplos, com a quantidade de itens entre parênteses.

6.6 Discussão

Carga e busca. Ambas crescem com N, conforme o percurso linear da base. O custo por registro varia mais nas menores amostras: na tabela selecionada, carga vai de 4,86 a 12,15 µs por registro em asteroides e de 48,06 a 62,66 µs em jogos; busca vai de 1,16 a 3,08 µs em asteroides e de 1,76 a 2,51 µs em jogos. Na base completa, o desvio padrão da carga foi 12,547 ms em asteroides e 105,172 ms em jogos. Para asteroides com $N = 50.000$, uma amostra de carga foi 275,523 ms e as outras foram 353,849 e 367,719 ms; todas foram mantidas.

Inserção no resultado com `array_list`. Medida em bloco, a inserção média na base completa foi 0,839 ms para 39.380 itens de asteroides e 2,433 ms para 125.811 itens de jogos, cerca de 0,02 µs por item.

Composição do total e saída. Na base completa, carga, busca, inserção e escrita representam 59,48%, 14,13%, 0,11% e 26,27% para asteroides, e 57,42%, 2,29%, 0,02% e 40,27% para

jogos. A escrita é a segunda maior fase nos dois casos. Para $k = 10$, o custo de saída é 37,63 µs por registro em asteroides e 60,30 µs em jogos; esse valor inclui abrir o arquivo e gravar o cabeçalho. O custo é $O(kp^2)$, pois cada coluna procura seu valor com `item_get`.

Estruturas avançadas. A Tabela 9 e a Figura 2 comparam os seis exemplos medidos. O custo por item foi 0,10 µs no array com 93 itens, 15,58 µs na lista ordenada com 5.501 itens, 0,52 µs na coleção cruzada com 12.919, 2,59 µs na generalizada com 6.145, 1,50 µs na cruzada com 43 e 2,32 µs na ordenada com 43. São casos diferentes e a comparação é qualitativa.

Limitações. Os experimentos controlados mantiveram base e resultado fixos (`linked_list`→ `array_list`). As estruturas avançadas aparecem apenas nos seis exemplos, que diferem em consulta, dataset e tamanho; a comparação da Tabela 9 é, portanto, qualitativa e não substitui um fatorial de benchmark. Cada medição se baseia em apenas três execuções, e a máquina não estava isolada (Seção 6.2). Cada configuração teve um aquecimento seguido de três medidas; o aquecimento não é gravado no CSV. Como o relógio mede CPU, esperas de disco não aparecem. Todas as medições foram feitas em uma única máquina.

7 Conclusão

As oito estruturas estão disponíveis pela mesma interface de coleção. A série de benchmark foi repetida para os dois datasets, com aquecimento e três medidas por configuração. Na base completa, a carga domina o tempo total e a escrita é a segunda maior fase.

Nos seis exemplos, os custos de inserção por item variaram de 0,10 a 15,58 µs. A lista cruzada agrupa itens com as mesmas chaves em uma lista por célula. Os exemplos diferem em consulta, dataset e quantidade de itens, então a comparação é qualitativa.